

Rúbrica de evaluación — Evidencia Bloque 1, Parte 1

Statistics for AI · Ponderación total: 100 puntos

Sección	Puntos	Criterio de evaluación
1. Data wrangling	30	Se parte de 30 puntos y se descuenta por error. Errores graves (−10 cada uno): no detectar o tratar mal los registros duplicados en la llave FABRICANTE–ID–AÑO–SEMANA (son 556 filas en 5 SKUs, y deben SUMARSE porque se refieren al mismo producto en la misma semana); colapsar mal de semanal a mensual (debe usarse FECHAM, no el mes derivado de FECHAW, porque hay semanas que cruzan meses); y promediar simple los precios en lugar de recalcularlos como $\Sigma \text{VENTA_VALOR} / \Sigma \text{LITROS}$. Errores menores (−2 a −5): no revisar valores nulos, no verificar la consistencia ID ↔ PRODUCTO, no documentar las decisiones de limpieza, no comprobar que los totales se conservan tras el colapso.
2a. Estadística descriptiva	15	Market share por año (en valor y/o volumen); identificación correcta de los fabricantes que hacen el 80% del mercado en los últimos 12 meses; evolución de ventas y precios en el tiempo; estadística descriptiva relevante; y sobre todo la LECTURA ESCRITA de lo que muestran las tablas y gráficas. Gráficas sin interpretación valen la mitad.
2b. Correlaciones	15	Que exista un análisis de correlación JUSTIFICADO (qué variables, en logaritmos o en niveles, a qué nivel de agregación y por qué), con matriz o gráfico, y con interpretación de los resultados. Correlacionar variables trivialmente redundantes (por ejemplo venta valor contra litros) sin discutirlo vale poco. Se premia correlacionar precio contra volumen, precios entre competidores o volúmenes entre productos, y notar la multicolinealidad entre precios.
3a. Especificación del modelo	15	Modelo log-log $\ln(\text{Litros}) \sim \ln(\text{Precio})$ estimado sobre el producto top del fabricante asignado (el de mayor venta en los últimos 12 meses), usando SOLO el precio como variable explicativa. Descuentos por: usar niveles sin logaritmos, usar semi-log sin justificarlo, identificar mal el producto top, o agregar el modelo al nivel de fabricante en vez de producto.
3b. Interpretación del modelo	25	Es la sección de mayor peso. Debe explicarse CON PALABRAS PROPIAS y correctamente: (i) el coeficiente β_1 como elasticidad —cambio porcentual en la cantidad ante 1% de cambio en el precio— y si la demanda es elástica o inelástica; (ii) el estadístico t y el p-value: qué hipótesis se prueba y si se rechaza; (iii) el intervalo de confianza al 95% y qué implica, sobre todo si contiene el cero; (iv) la R^2 y qué tanto explica el modelo; (v) idealmente, por qué el resultado puede ser engañoso (sesgo por variable omitida, tendencia, estacionalidad, endogeneidad, autocorrelación). Se penaliza con fuerza: interpretar β_1 como pesos o como cambio absoluto en lugar de porcentaje; afirmar que un coeficiente NO significativo demuestra que el precio sí afecta la demanda; confundir R^2 con significancia; interpretar el signo al revés; o una interpretación genérica que no usa los números propios. Una interpretación ausente o de una sola línea no pasa de 5 puntos.

Retroalimentación — Evidencia Bloque 1, Parte 1

Martínez Ibarra, Kamila Jeannette

Fabricante asignado FAB2

Producto top utilizado FAB2_ Deslac Deslactosada 1 L

Sección	Obtenido	Máximo	Promedio grupo	Mediana grupo	Qué se evaluó	Correcciones
1. Data wrangling	3.0	30.0	20.1	22.0	Nulos, duplicados FAB–ID–AÑO–SEMANA, colapso semanal→mensual con FECHAM, precios ponderados, estructura del panel.	Se detectaron 556 filas / 278 llaves con la misma FABRICANTE-ID-AÑO-SEMANA y se sumaron en vez de solo correr df.duplicated(). Se eliminaron las devoluciones sueltas en vez de aplicarles abs() Se creo un panel mensual. Se recalculó como suma(VENTA_VALOR)/suma(LITROS) en vez de mean(PRECIO_UNITARIO_LITRO), en el desempeño anual y en el mensual por producto. Se limpiaron espacios extra y dobles espacios en la columna ID.
2a. Estadística descriptiva	9.0	15.0	11.0	12.0	Market share por año, top-80% en los últimos 12 meses, evolución de ventas y precios, descriptivos e interpretación escrita.	El 80% de market share se recalculó sobre los últimos 12 meses, antes usaba el año 2025. Se corrigió el texto "incorporación del fabricante 3" a "fabricante 5".
2b. Correlaciones	7.0	15.0	8.0	8.0	Análisis de correlación justificado, con matriz o gráfico e interpretación de los resultados.	Antes se calculaba pero se descartaba la matriz de Spearman, y se mostraba Pearson duplicado. La matriz de correlación de FAB2 usaba una versión de datos sucios, se corrigió para usar el df ya limpio. Se corrigió el título del heatmap de todo el dataset, que decía "(FAB2)" por error.
3a. Especificación del modelo	14.0	15.0	9.9	13.0	Modelo log-log ln(Litros) ~ ln(Precio) sobre el producto top correcto, solo con precio como explicativa.	
3b. Interpretación del modelo	11.0	25.0	10.8	11.0	Lectura del coeficiente como elasticidad, estadístico t, p-value, intervalo de confianza al 95%, R² y limitaciones del modelo.	Se planteó explícitamente la hipótesis nula para precio, tendencia y meses, usando el p-value para rechazar o no cada hipótesis. Se agregó el t-statistic (-10.72 en el modelo simple, -7.27 en el extendido). Se agregó el intervalo de confianza al 95% a la explicación. Se corrigió la interpretación de R2. Se cuestionó la credibilidad de una elasticidad de -5.26, tomando en consideración la cantidad de semanas con las que estamos corriendo el modelo. Se corrigió "-5.26% pasó a -3.86%" , estas no son porcentajes.
CALIFICACIÓN TOTAL	44.0	100.0	59.9	60.0	El grupo (27 entregas) promedió 59.9 y su mediana fue 60.0. Rango del grupo: 27 a 99.	

Retroalimentación general del proyecto
Hiciste varias revisiones que sí valen: verificaste que ningún ID tuviera dos nombres y ningún producto dos IDs, comprobaste que PRECIO_UNITARIO_PAQUETE = UNIDADES_EN_PAQUETE * PRECIO_UNITARIO_LITRO, y detectaste los valores negativos con describe(). Pero el wrangling tiene tres problemas serios. Primero, los duplicados: solo corriste df.duplicated(), que busca filas idénticas completas y por eso te dio cero; en este archivo hay 556 filas (278 llaves) con el mismo FABRICANTE-ID-AÑO-SEMANA que son registros parciales de la misma semana y había que SUMARLAS. Nunca las viste, y de hecho en tu propio conteo por producto-mes debiste haber notado meses con 8 y 10 registros. Segundo, aplicaste abs() a VENTA_VALOR, LITROS y PAQUETES: esos negativos son devoluciones, y convertir -46,992 litros de FAB3 en +46,992 no 'corrige' nada, te suma volumen inventado (por eso tu share 2024 de FAB1 sale 41.09 en vez de 41.4); lo correcto era eliminarlas o netearlas. Tercero, tiraste la columna FECHAM diciendo que la información se puede sacar de FECHAW, y eso es justo al revés: FECHAM existe porque hay semanas que cruzan meses, así que al derivar el mes de FECHAW partes semanas entre meses. Nunca construiste el panel mensual que pedía el enunciado ni justificaste quedarte en semanal. Además, cada vez que agregaste precios usaste mean() de PRECIO_UNITARIO_LITRO, que pesa igual una semana chica que una enorme; el precio agregado se recalcula como suma de VENTA_VALOR entre suma de LITROS. Tampoco atendiste los 3 nulos de precio (se ven en el describe como count 3293) ni limpiaste los IDs con y espacios dobles. En lo descriptivo tu market share anual en valor está bien calculado y presentado, pero el 80% lo sacaste del año 2025, que son solo 7 meses, no de la ventana de últimos 12 meses que se pedía; el conjunto (FAB1, FAB3, FAB5) te salió bien de casualidad. Cuida también los errores de lectura: escribiste 'la incorporación del fabricante 3 al mercado' cuando el que entra es FAB5.

Retroalimentación de la interpretación del modelo de regresión
Tu interpretación del modelo son tres oraciones y eso es muy poco para lo que valía este apartado. Lo que sí está bien: lees el coeficiente como elasticidad en porcentaje, 'si el precio aumenta 1%, la demanda de litros disminuye 5.26%', que es la lectura correcta de un log-log; nunca lo confundiste con pesos. Pero no dices en ningún momento que eso significa una demanda muy elástica, ni te detienes a preguntarte si un -5.26 es creíble (es enorme, y viene de estimar con solo 53 semanas del último año). Del p-value dices 'dando 0, es sumamente confiable esa relación': no planteaste la hipótesis nula H0: beta1 = 0 ni el rechazo, y 'sumamente confiable' es una lectura floja, el p-value no mide qué tan confiable es la relación sino qué tan improbable es tu estadístico si el precio no tuviera efecto. El estadístico t (-10.72) no lo mencionas y el intervalo de confianza al 95%, [-6.246, -4.276], no aparece en absoluto, siendo que era uno de los puntos que se pedía interpretar explícitamente. Con la R² cometes el error clásico: dices que 'el alto valor de R2 también nos confirma la dependencia del precio', y la R² no confirma dependencia ni significancia, solo mide qué proporción de la variación de log(litros) queda explicada; se salva un poco porque agregas que deja abierta la posibilidad de otros factores. Lo mejor de tu trabajo interpretativo está en la Etapa 4, donde sí razones que el modelo simple cargaba todo el efecto sobre el precio y que al meter tendencia y estacionalidad el sesgo se reparte y la elasticidad baja a -3.87; eso es sesgo por variable omitida bien intuitivo y te subió la calificación. Ojo con dos cosas ahí: escribes '-5.26% pasó a -3.86%', y esos números son elasticidades, no porcentajes; y 'el mejor modelo es el segundo ya que cuenta con un R2' no es un argumento, los dos tienen R². Faltó por completo hablar de la autocorrelación, que tu propio Durbin-Watson de 1.097 estaba gritando.